模型选型在 V100 环境下评估结论

Model Service Evaluation Summary

> Updated: 2026-03-22

说明

- `可启动`： vLLM Docker 服务可拉起。
- `可服务`： 可通过 OpenAI-compatible `/v1/chat/completions` 提供稳定响应。
- `智能体能跑`： 能承载 Goose / tool use / agentic 场景。
- `可交付`： 在当前环境与目标下，值得进入下一阶段集成。
- `最低硬件建议`： 优先采用官方 serving 示例；官方未给出时，按模型规模、精度类型和当前测试目标做保守工程推断，不等同于厂商承诺下限。

总表

模型	首次公开发布时间	最低硬件配置需求	可启动	可服务	性能结论	智能体能跑	可交付	备注
Qwen3.5-35B-A3B	2026-02-24	**不建议V100；最低建议Ampere，4×32GB**	NO	NO	未进入有效测试	未验证	NO	官方示例口径偏TP=8，这类新一代A3B/MoE模型更适合Ampere/Hopper及以

								上，当前阶段淘汰
Qwen3.5-27B	2026-02-24	**不建议V100；最低建议Ampere，4×32GB**	NO	NO	未进入有效测试	未验证	NO	同上，当前阶段淘汰
GLM4.7-Flash	2025-08-08	**不建议V100；最低建议Ampere，4×32GB**	NO	NO	未进入有效测试	未验证	NO	这类新模型更应按BF16/Ampere起步来写，当前阶段淘汰
GPT-OSS-20B	2025-08-05	**若走官方低比特路径：最低建议Hopper，1×80GB；若走BF16：最低建议Ampere，**	NO	NO	未进入有效测试	未验证	NO	官方默认强调MXFP4，Hopper 或更新架构支持更合适；若退回BF16，显存需求会明显增大

		2×32GB						
Cohere Command-R-08-2024	2024-08-30	**V100 可用；最低建议 4×32GB**	YES	YES	好；基础服务稳定，输出 TPS 约 45	NO	NO	这一项最适合保留成“V100 可服务”的正例；Cohere 也明确说 08-2024 版硬件占用相比上一版下降
Qwen3-30B-A3B-Thinking-2507	2025-07-29	**V100 可启动但不建议；最低建议 Ampere，4×32GB；更优 Hopper**	YES	YES	差；当前 vLLM + V100 上 MoE 路径异常慢，8K 左右首 token 超过 60s	YES	NO	不建议在当前 V100 环境继续投入
Qwen3-32B	2025-04-29	**V100 可用；最低建议 4×32GB；更**	YES	YES	中；长上下文下 TTFT 约 8s-16s，	YES	YES	当前最均衡的候选

		优 2×80GB / 4×40GB Ampere			输出 TPS 约 17			

关键结论

- 当前唯一建议继续推进的模型是 `Qwen3-32B` 。
- `Cohere Command-R-08-2024` 适合普通服务，不适合 Goose / tools。
- `Qwen3-30B-A3B-Thinking-2507` 的主要问题更像是当前 `vLLM + V100` 组合下的 MoE 路径性能异常，而不是单纯的 thinking 输出成本；在当前环境不建议继续投入。

最终建议

- 主选： `Qwen3-32B`
- 备选： `Cohere Command-R-08-2024` ，仅限不依赖 Goose / tools 的普通服务场景
- 暂停： `Qwen3-30B-A3B-Thinking-2507` 及其余未进入有效测试或未通过启动验证的模型

来源

- Qwen3.5 模型页与 vLLM / SGLang serving 示例： Qwen/Qwen3.5-35B-A3B 、 Qwen/Qwen3.5-27B
- Qwen3 主模型页： Qwen/Qwen3-32B
- Qwen3 MoE Thinking 模型页： Qwen/Qwen3-30B-A3B-Thinking-2507
- Cohere 模型页： CohereLabs/c4ai-command-r-08-2024
- OpenAI 开源模型页： openai/gpt-oss-20b
- GLM 模型页： zai-org/GLM-4.7-Flash